



**FOM Hochschule für Oekonomie & Management**

Hochschulzentrum Hamburg

**Bachelor Thesis**

im Studiengang Informatik

zur Erlangung des Grades eines

**Bachelor of Science (B.Sc.)**

über das Thema

**Implementierung des Equilibrium Propagation Algorithmus auf analogen  
Computern für das Trainieren neuronaler Netze**

von

**Merlin Moelter**

Betreuer : Dipl.-Phys.Ing. Stefan Scharr

Matrikelnummer : 575141

Abgabedatum : 12. Dezember 2024

# Inhaltsverzeichnis

<b>Abbildungsverzeichnis</b>	<b>III</b>
<b>Tabellenverzeichnis</b>	<b>IV</b>
<b>Abkürzungsverzeichnis</b>	<b>V</b>
<b>Symbolverzeichnis</b>	<b>VI</b>
<b>Glossar</b>	<b>VII</b>
<b>1 Einleitung</b>	<b>1</b>
<b>2 Grundlagen</b>	<b>2</b>
2.1 Neuronale Netze . . . . .	2
2.1.1 Aufbau und Arten neuronaler Netze . . . . .	2
2.1.2 Training neuronaler Netze mit Backpropagation und Gradient Descent	4
2.2 Analoge Computer . . . . .	4
2.2.1 Geschichte zu analogen Computern . . . . .	4
2.2.2 Typische Komponenten und Bauweisen analoger Computer . . . . .	4
2.2.3 Aufbau von Schaltkreisen zur Lösung von Differenzialgleichungen .	4
2.3 Energiebasierte Modelle . . . . .	4
2.3.1 Definition: Energiebasierte Modelle und energiebasiertes Lernen . .	4
2.3.2 Das Hopfield-Netzwerk: Eine Herangehensweise an neuronale Netze	4
2.3.3 Energiebasiertes Lernen am Beispiel Equilibrium Propagation . . .	4
2.3.3.1 Mathematische Grundlagen . . . . .	4
2.3.3.2 Theoretische Anwendung am Beispiel eines Hopfield- Netzwerks . . . . .	4
<b>Anhang</b>	<b>5</b>
<b>Literaturverzeichnis</b>	<b>6</b>

## **Abbildungsverzeichnis**

## **Tabellenverzeichnis**

## **Abkürzungsverzeichnis**

## **Symbolverzeichnis**

## Glossar

**Bias-Neuron** Zusätzliches Neuron, welches Konstant den Wert 1 ausgibt. Durch gewichtete Verbindungen kann jedem Neuron der nachfolgenden Ebene ein Bias-Wert zugewiesen werden.. 3

**CNN** Convolutional Neural Network; Neuronales Netz mit Convolutional-Ebenen, welche nur mit jeweils einem Ausschnitt der vorherigen Ebene verbunden sind.. 3

**Dense Layer** Ebene eines neuronalen Netzes, in der jedes Neuron mit jedem Neuron der vorherigen Ebene verbunden ist. 3

**DNN** Deep Neuronal Network; Neuronales Netz mit vielen versteckten Ebenen.. 3

**FNN** Feedforward Neural Network; Neuronales Netz, in dem Signal nur in eine Richtung geleitet werden.. 3

**Fully Connected Layer** Siehe "Dense Layer". 3

**MLP** Multilayer-Perceptron; Eine Zusammensetzung an Perceptrons mit einer Eingabe-Ebene, mindestens einer versteckten Ebene und einer Ausgabe-Ebene.. 3

**Perceptron** Sammlung an TLUs auf einer einzelnen Ebene. 2, 3

**RNN** Recurrent Neural Network; Neuronales Netz mit rückwärtigen Verbindungen, Hauptbestandteil ist hier die Speicherzelle.. 3

**TLU** Threshold Logic Unit; Berechnet die gewichtete Summe seiner Eingabewerte und gibt abhängig von der Überschreitung eines Schwellenwerts entweder 0 oder 1 aus.. 2, 3

## **1 Einleitung**



## 2 Grundlagen

### 2.1 Neuronale Netze

#### 2.1.1 Aufbau und Arten neuronaler Netze

„Birds inspired us to fly, burdock plants inspired Velcro, and nature has inspired countless more inventions. It seems only logical then, to look at the brain's architecture for inspiration on how to build an intelligent machine“ (Géron, A., 2019, S. 279)

Neuronale Netze wurden erstmals 1943 von den Wissenschaftlern Warren S. McCulloch und Walter Pitts in ihrer gemeinsamen Arbeit „A logical calculus of the ideas immanent in nervous activity“ (McCulloch, W. S., Pitts, W., 1943) eingeführt. Sie stellten ein vereinfachtes Modell eines künstlichen Neurons vor, das lediglich aus binären Eingaben und einer binären Ausgabe besteht und seine Ausgabe aktiviert, sobald sich eine bestimmte Anzahl an Eingabewerten aktiviert. McCulloch und Pitts zeigten, dass dieser einfache Baustein ausreicht, um jeden möglichen logischen Ausdruck als neuronales Netz darzustellen.

Neuronale Netze zeichnen sich mittlerweile durch ihre Vielseitigkeit, Leistungsfähigkeit und Skalierbarkeit aus und haben damit maßgeblich zur Gründung eines neuen Forschungsfeldes, dem „Deep Learning“, beigetragen. (Géron, A., 2019) Die neu gewonnen Aufmerksamkeit im Zusammenhang mit Deep Learning brachte Innovationen wie das von OpenAI entwickelte Sprachmodell „GPT-4“ oder der Bildgenerierungs-KI „Midjourney“ hervor, wodurch bewiesen wurde, dass neuronale Netze zur Lösung komplexer Aufgaben geeignet sind und sogar teilweise ähnlich brauchbare Ergebnisse wie ein Mensch liefern können. (OpenAI et al., 2024)

Eines der einfachsten neuronalen Netze ist das von Rosenblatt, F., 1958 vorgestellte Perceptron, dieses basiert auf dem Konzept der TLU. Die Eingabe- und Ausgabewerte einer TLU sind numerisch und den eingehenden Verbindungen ist jeweils eine Gewichtung zugewiesen. Die TLU berechnet nun die gewichtete Summe der Eingabewerte  $z = w_1x_1 + w_2x_2 + \dots + w_nx_n = \sum w_i x_i$ . Unter Anwendung einer Aktivierungsfunktion  $hw(x) = \text{step}(z)$  kann nun berechnet werden, ob die TLU den Wert 0 oder 1 ausgibt. Eine Aktivierungsfunktion für diese Art der Neuronen ist i. d. R. eine Heaviside-Funktion oder eine Vorzeichen-Funktion. Géron, A., 2019, S. 284 ff.

Aktivierungsfunktionen aus Buch einfügen

Abbildung aus Buch nachstellen

Eine alleinstehende TLU kann ausschließlich für lineare binäre Klassifikation genutzt werden, es berechnet eine gewichtete Summe anhand der Eingabewerte und gibt einen positiven oder negativen Ausgabewert, abhängig von der Überschreitung eines Schwellenwertes. Ein Perceptron stellt nun eine Sammlung dieser Einheiten auf einer einzelnen Ebene dar, wobei jede TLU mit jeder Eingabe verbunden ist. Dies wird als Dense Layer oder Fully Connected Layer bezeichnet. Die Eingabewerte des Perceptron werden durch Eingabe-Neuronen geschleust, wozu zusätzlich ein Bias-Neuron gezählt wird. Dieses Neuron gibt konstant den Wert 1 aus und dient dazu, jedem Neuron des Perceptron eine Bias-Gewichtung zuzuweisen. Die Ausgabe eines Perceptron berechnet sich durch  $h_W, b(X) = p(XW + b)$  Géron, A., 2019, S. 284 ff.

Das Perceptron kann nun in mehreren Ebenen genutzt werden, um ein MLP zu erzeugen. Dieses besteht aus einer Eingabe-Ebene, mindestens einer versteckten Ebene und einer Ausgabe-Ebene. Jede dieser Ebenen ist im MLP mit der jeweils nächsten Ebene vollständig verbunden. Das MLP kann durch die vorwärts gerichteten Verbindungen auch als FNN bezeichnet werden, eines mit vielen versteckten Ebenen wird DNN genannt. ebd., S. 284 ff.

Das bisher beschriebene MLP kann zur Klassifikation genutzt werden. Um dieses auch auf Regressionen anwenden zu können, muss die Aktivierungsfunktion entweder entfernt oder durch z.B. ReLU ausgetauscht werden, damit die Ausgabeneuronen willkürliche Werte annehmen können. Die Anzahl der Ausgabe-Neuronen muss in dem Fall angepasst werden, sodass jeder geforderte Ausgabewert durch ein Neuron abgebildet ist. ebd., S. 292 ff.

Eine weitere Art des neuronalen Netz ist das CNN, dessen Hauptbestandteil die Convolutional-Ebenen sind. Diese Ebenen sind nur jeweils mit einem Ausschnitt der vorherigen Ebene verbunden, wodurch das daraus entstehende neuronale Netz abstrakte Eigenschaften der Eingabe-Neuronen erlernen kann. Da die einzelnen Ebenen hier nicht, wie beim MLP, vollständig verbunden sind, erlaubt ein CNN eine große Anzahl an Neuronen pro Ebene, ohne den Rechenaufwand für Training und Inferenz exponentiell zu steigern. Durch diese Eigenschaften eignet sich das CNN besonders für die Bildbearbeitung, da hier als Eingabe die Pixel genutzt und darin Eigenschaften des Bildes gefunden werden können. ebd., S. 447 f.

Das RNN ähnelt vom Aufbau dem FNN unterscheidet sich aber durch rückwärts gerichtete Verbindungen. Die Ausgabe eines Neuron wird damit Teil seiner Eingabe, womit es sich Informationen "merken" kann. Ein RNN kann als Sequenz-zu-Sequenz Netzwerk genutzt werden, es erhält also eine Sequenz an Eingabe-Werten und produziert eine Sequenz an Ausgabe-Werten. Genauso kann jeder Ausgabewert bis auf den letzten ignoriert werden, was als Sequenz-zu-Vektor Netzwerk bezeichnet wird. Andersherum kann ein RNN

auch einen Vektor als Eingabe erhalten und eine Sequenz ausgeben, wodurch z.B. eine Beschreibung für ein Bild generiert werden könnte. Letztlich ist auch ein sog. Encoder-Decoder Modell möglich, wobei ein Sequenz-zu-Vektor Netzwerk zuerst eine Repräsentation der Eingabesequenz erzeugt, und ein Vektor-zu-Sequenz Netzwerk daraufhin eine Ausgabe aus dieser Repräsentation erzeugt. Ein Anwendungsfall dafür sind Sprachanwendungen wie ein Übersetzer, da jedes Wort eines Textes im Vorhinein bekannt sein muss, um eine korrekte Ausgabe zu erzeugen. *Géron, A.*, 2019, S. 497 ff.

### **2.1.2 Training neuronaler Netze mit Backpropagation und Gradient Descent**

## **2.2 Analoge Computer**

### **2.2.1 Geschichte zu analogen Computern**

### **2.2.2 Typische Komponenten und Bauweisen analoger Computer**

### **2.2.3 Aufbau von Schaltkreisen zur Lösung von Differenzialgleichungen**

## **2.3 Energiebasierte Modelle**

### **2.3.1 Definition: Energiebasierte Modelle und energiebasiertes Lernen**

### **2.3.2 Das Hopfield-Netzwerk: Eine Herangehensweise an neuronale Netze**

### **2.3.3 Energiebasiertes Lernen am Beispiel Equilibrium Propagation**

#### **2.3.3.1 Mathematische Grundlagen**

#### **2.3.3.2 Theoretische Anwendung am Beispiel eines Hopfield-Netzwerks**

## Anhang

## Literaturverzeichnis

*Géron, Aurélien* (2019): Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, 2. Aufl., o. O.: O'Reilly Media, 2019

*McCulloch, Warren S., Pitts, Walter* (1943): A logical calculus of the ideas immanent in nervous activity, in: The Bulletin of Mathematical Biophysics, 5 (1943), Nr. 4, S. 115–133

*OpenAI, Achiam, Josh, Adler, Steven, Agarwal, Sandhini, Ahmad, Lama, Akkaya, Ilge, Aleman, Florencia Leoni, Almeida, Diogo, Altschmidt, Janko, Altman, Sam, Anadkat, Shyamal, Avila, Red, Babuschkin, Igor, Balaji, Suchir, Balcom, Valerie, Baltescu, Paul, Bao, Haiming, Bavarian, Mohammad, Belgum, Jeff, Bello, Irwan, Berdine, Jake, Bernadett-Shapiro, Gabriel, Berner, Christopher, Bogdonoff, Lenny, Boiko, Oleg, Boyd, Madeline, Brakman, Anna-Luisa, Brockman, Greg, Brooks, Tim, Brundage, Miles, Button, Kevin, Cai, Trevor, Campbell, Rosie, Cann, Andrew, Carey, Brittany, Carlson, Chelsea, Carmichael, Rory, Chan, Brooke, Chang, Che, Chantzis, Fotis, Chen, Derek, Chen, Sully, Chen, Ruby, Chen, Jason, Chen, Mark, Chess, Ben, Cho, Chester, Chu, Casey, Chung, Hyung Won, Cummings, Dave, Currier, Jeremiah, Dai, Yunxing, Decareaux, Cory, Degry, Thomas, Deutsch, Noah, Deville, Damien, Dhar, Arka, Dohan, David, Dowling, Steve, Dunning, Sheila, Ecoffet, Adrien, Eleti, Atty, Eloundou, Tyna, Farhi, David, Fedus, Liam, Felix, Niko, Fishman, Simón Posada, Forte, Juston, Fulford, Isabella, Gao, Leo, Georges, Elie, Gibson, Christian, Goel, Vik, Gogineni, Tarun, Goh, Gabriel, Gontijo-Lopes, Rapha, Gordon, Jonathan, Grafstein, Morgan, Gray, Scott, Greene, Ryan, Gross, Joshua, Gu, Shixiang Shane, Guo, Yufei, Hallacy, Chris, Han, Jesse, Harris, Jeff, He, Yuchen, Heaton, Mike, Heidecke, Johannes, Hesse, Chris, Hickey, Alan, Hickey, Wade, Hoeschele, Peter, Houghton, Brandon, Hsu, Kenny, Hu, Shengli, Hu, Xin, Huizinga, Joost, Jain, Shantanu, Jain, Shawn, Jang, Joanne, Jiang, Angela, Jiang, Roger, Jin, Haozhun, Jin, Denny, Jomoto, Shino, Jonn, Billie, Jun, Heewoo, Kaftan, Tomer, Kaiser, Łukasz, Kamali, Ali, Kanitscheider, Ingmar, Keskar, Nitish Shirish, Khan, Tabarak, Kilpatrick, Logan, Kim, Jong Wook, Kim, Christina, Kim, Yongjik, Kirchner, Jan Hendrik, Kiros, Jamie, Knight, Matt, Kokotajlo, Daniel, Kondraciuk, Łukasz, Kondrich, Andrew, Konstantinidis, Aris, Kosic, Kyle, Krueger, Gretchen, Kuo, Vishal, Lampe, Michael, Lan, Ikai, Lee, Teddy, Leike, Jan, Leung, Jade, Levy, Daniel, Li, Chak Ming, Lim, Rachel, Lin, Molly, Lin, Stephanie, Litwin, Mateusz, Lopez, Theresa, Lowe, Ryan, Lue, Patricia, Makanju, Anna, Malfacini, Kim, Manning, Sam, Markov, Todor, Markovski, Yaniv, Martin, Bianca, Mayer, Katie, Mayne, Andrew, McGrew, Bob, McKinney, Scott Mayer, McLeavey, Christine, McMillan, Paul, McNeil, Jake, Medina, David, Mehta, Aalok, Menick, Jacob, Metz, Luke, Mishchenko, Andrey, Mishkin, Pamela, Monaco, Vinnie, Morikawa, Evan, Mossing, Daniel, Mu, Tong, Murati, Mira, Murk, Oleg, Mély, David, Nair, Ashvin, Nakano, Reiichiro, Nayak, Rajeev, Neelakantan, Arvind, Ngo, Richard, Noh, Hyeonwoo, Ouyang, Long, O'Keefe, Cullen, Pachocki, Jakub, Paino, Alex, Palermo, Joe, Pantuliano, Ashley, Parascandolo, Giambattista, Parish, Joel, Parpari-*

ta, Emy, Passos, Alex, Pavlov, Mikhail, Peng, Andrew, Perelman, Adam, de Avila Belbute Peres, Filipe, Petrov, Michael, de Oliveira Pinto, Henrique Ponde, Michael, Pokorny, Pokrass, Michelle, Pong, Vitchyr H., Powell, Tolly, Power, Alethea, Power, Boris, Proehl, Elizabeth, Puri, Raul, Radford, Alec, Rae, Jack, Ramesh, Aditya, Raymond, Cameron, Real, Francis, Rimbach, Kendra, Ross, Carl, Rotsted, Bob, Roussez, Henri, Ryder, Nick, Saltarelli, Mario, Sanders, Ted, Santurkar, Shibani, Sastry, Girish, Schmidt, Heather, Schnurr, David, Schulman, John, Selsam, Daniel, Sheppard, Kyla, Sherbakov, Toki, Shieh, Jessica, Shoker, Sarah, Shyam, Pranav, Sidor, Szymon, Sigler, Eric, Simens, Maddie, Sitkin, Jordan, Slama, Katarina, Sohl, Ian, Sokolowsky, Benjamin, Song, Yang, Staudacher, Natalie, Such, Felipe Petroski, Summers, Natalie, Sutskever, Ilya, Tang, Jie, Tezak, Nikolas, Thompson, Madeleine B., Tillet, Phil, Tootoonchian, Amin, Tseng, Elizabeth, Tuggle, Preston, Turley, Nick, Tworek, Jerry, Uribe, Juan Felipe Cerón, Vallone, Andrea, Vijayvergiya, Arun, Voss, Chelsea, Wainwright, Carroll, Wang, Justin Jay, Wang, Alvin, Wang, Ben, Ward, Jonathan, Wei, Jason, Weinmann, CJ, Welihinda, Akila, Welinder, Peter, Weng, Jiayi, Weng, Lilian, Wiethoff, Matt, Willner, Dave, Winter, Clemens, Wolrich, Samuel, Wong, Hannah, Workman, Lauren, Wu, Sherwin, Wu, Jeff, Wu, Michael, Xiao, Kai, Xu, Tao, Yoo, Sarah, Yu, Kevin, Yuan, Qiming, Zaremba, Wojciech, Zellers, Rowan, Zhang, Chong, Zhang, Marvin, Zhao, Shengjia, Zheng, Tianhao, Zhuang, Juntang, Zhuk, William, Zoph, Barret (2024): GPT-4 Technical Report, o. O., 2024, arXiv: 2303.08774 [cs.CL], URL: <https://arxiv.org/abs/2303.08774>

*Rosenblatt, F.* (1958): The perceptron: A probabilistic model for information storage and organization in the brain. In: *Psychological Review*, 65 (1958), Nr. 6, S. 386–408

---

## Ehrenwörtliche Erklärung

Hiermit versichere ich, dass die vorliegende Arbeit von mir selbstständig und ohne unerlaubte Hilfe angefertigt worden ist, insbesondere dass ich alle Stellen, die wörtlich oder annähernd wörtlich aus Veröffentlichungen entnommen sind, durch Zitate als solche gekennzeichnet habe. Ich versichere auch, dass die von mir eingereichte schriftliche Version mit der digitalen Version übereinstimmt. Weiterhin erkläre ich, dass die Arbeit in gleicher oder ähnlicher Form noch keiner Prüfungsbehörde/Prüfungsstelle vorgelegen hat. Ich erkläre mich damit **einverstanden/nicht einverstanden**, dass die Arbeit der Öffentlichkeit zugänglich gemacht wird. Ich erkläre mich damit einverstanden, dass die Digitalversion dieser Arbeit zwecks Plagiatsprüfung auf die Server externer Anbieter hochgeladen werden darf. Die Plagiatsprüfung stellt keine Zurverfügungstellung für die Öffentlichkeit dar.

Hamburg, 12.12.2024

(Ort, Datum)

A handwritten signature in black ink, consisting of a large, stylized 'H' followed by a series of loops and a final flourish.

\_\_\_\_\_  
(Eigenhändige Unterschrift)